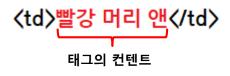
- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

웹 크롤링이라는 것은 웹 페이지의 하이퍼 링크를 순회하면서 웹 페이지를 다운로드하는 작업이며 웹 스크레핑은 다운로드한 웹 페이지에서 필요한 컨텐트를 추출하는 작업입니다.

즉, 웹 페이지를 구성하고 있는 HTML 태그의 컨텐트나 속성의 값을 읽는 작업을 의미합니다.



(a href="https://www.python.org/">파이썬〈/a〉 태그의 속성값



- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

### [ URL ] URL(Uniform Resource Locator)은 네트워크 상에서 자원이 어디 있는지를 알려주기 위한 규약입니다.

컴퓨터 네트워크와 검색 메커니즘에서의 자원의 위치를 지정하는 문자열로서 다음과 같이 프로토콜정보, 도메인 정보 그리고 요청 대상(URI)로 구성됩니다.



URI(Uniform Resource Identity)는 웹 사이트에 요청하고자 하는 대상의 패스정보와 파일명으로 구성되며 파일명이 생략되면 디폴트로 index.html 이 사용됩니다.



- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

#### [HTTP]

HTTP(HyperText Transfer Protocol)는 웹상에서 클라이어트와 서버간에 정보를 주고받을 수 있는 통신 규약 (프로토콜)입니다. 주로 URL 문자열을 직접 입력하거나 하이퍼링크 텍스트 또는 이미지를 클릭하여 HTML 문서를 주고받는 데에 사용됩다. 디폴트로 80번 포트를 사용하지만 다른 포트 번호를 사용하는 웹서버에 요청할 때는 도메인명 뒤에

: 기호와 함께 포트 번호를 지정해야 합니다

웹 클라이언트에서 웹 서버에 HTTP 요청을 전달할 때는 요청 방식이라는 것을 명시해야 합니다. 다양한 요청 방식이 지원되지만 일반적으로 GET 방식과 POST 방식만 알고 있으면 됩니다. HTTP요청

HTTP응답

- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

[ GET 방식과 POST 방식 ]

브라우저에서 직접 요청하여는 페이지의 URL 문자열을 입력하여 요청하는 것은 GET 방식 요청입니다. 하이퍼링크가 설정된 텍스트나 이미지를 클릭하여 요청하는 것도 GET 방식 요청입니다. 〈form〉태그를 통한 요청은 method 속성 값에 따라서 GET 방식 요청과 POST 방식 요청 모두 가능 합니다. Query 문자열이라는 것은 웹 브라우저가 웹 서버에게 요청을 보내면서 함께 전달되는 name과 value 로 구성되는 문자열입니다.

GET 방식 - Query 문자열 없는 요청과 Query 문자열을 추가한 요청 모두 가능다음과 같이 Query 문자열이 URL 문자열 뒤에 추가되어 전달됩니다. https://movie.daum.net/moviedb/main?movield=126260

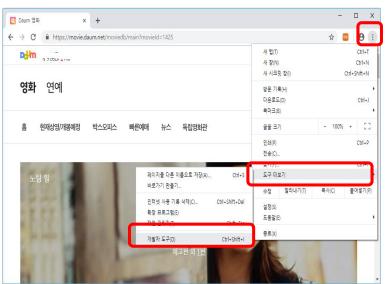
POST - Query 문자열을 추가한 요청만 가능하며 Query 문자열이 요청 바디에 따로 담겨서 전달되므로 요청 URL 문자열에서는 볼 수 없습니다.

- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

다음 사이트의 영화페이지를 요청한 다음 크롬의 개발자 도구를 기동시키기 위한 화면입니다. 크롬 브라우저에서

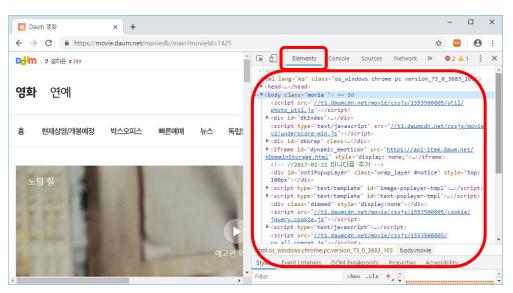
https://movie.daum.net/moviedb/main?movield=1425

을 입력하고 요청한 다음 오른쪽 상단의 크롬 맞춤설정 및 제어라는 메뉴를 클릭한 다음 도구 더보기 메뉴의 개발자 도구 메뉴를 클릭합니다.



- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

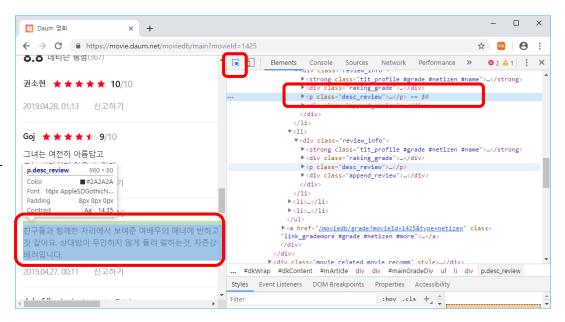
그러면 오른편으로 개발자 도구가 출력됩니다. Elements 탭을 클릭하면 브라우저에서 랜더링 되고 있는 웹 페이지의 HTML 소스가 출력되는 것을 볼 수 있습니다.



출처: https://movie.daum.net/

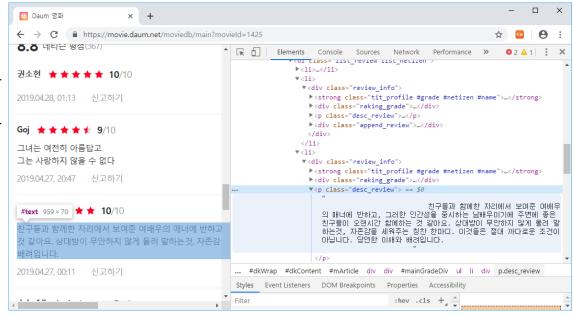
- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

개발자 도구의 왼쪽 상단의 버튼을 클릭한 후에 찾고자 하는 페이지의 컨텐트를에 마우스를 올려 놓으면 이 컨텐트를 담고 있는 HTML 태그 부분이 개발자도구의 태그 영역을 표시해주므로 찾고자하는 컨텐트의 태그를 쉽게 찾을 수 있게지원합니다.



- ◈ 빅 데이터 수집 방법
  - 웹 크롤링과 웹 스크래핑

개발자 도구에서 해당 태그영역을 클릭하면 그 태그의 컨텐트 영역의 내용 이 출력되면 웹 페이지에 랜더링된 내용과 동일하다는 것을 확인할 수 있습 니다.



- ◈ 빅 데이터 수집 방법
  - 공공 데이터

공공 데이터란 공공기관이 전자적으로 생성 또는 취득하여 관리하고 있는 모든 데이터베이스(DB), 전자화된 파일입니다.

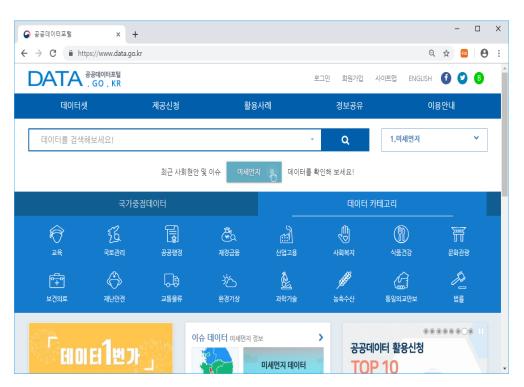
공공 데이터 개방이란 공공기관이 이용자에게 정보를 재활용할 수 있도록 제공하고, 제공받은 정보를 상업적·비영리적으로 이용할 권한을 부여하는 것입니다.

정부는 보유하고 있는 공공 데이터를 적극적으로 개방하여 국민과 공유함으써 소통과 협력을 확대하기 위해 공공데이터 정책을 추진하게 되었고, 2013년 7월 공공 데이터법을 제정하고 공공데이터 개방을 10월부터 시행 하였습니다.

- ◈ 빅 데이터 수집 방법
  - 공공 데이터

공공 데이터 포털은 공공기관이 생성 또는 취득하여 관리하고 있는 공공데이터를 한 곳에서 제공하는 통합 창구입니다.

포털에서는 국민이 쉽고 편리하게 공공데이터를 이용할 수 있도록 파일데이터, 오픈API, 시각화 등 다양한 방식으로 제공 하고 있으며, 누구라도 쉽고 편리한 검색을 통해 원하는 공공데이터를 빠르고 정확하게 찾을 수 있습니다.



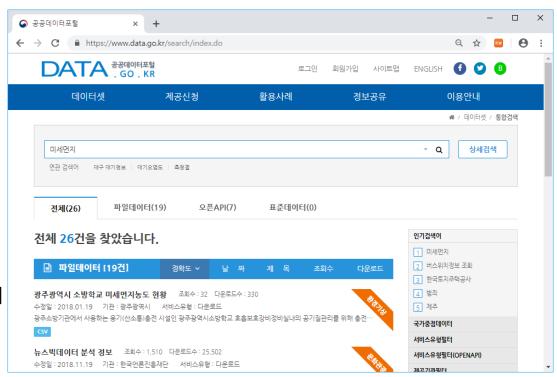
출처 : https://www.data.go.kr/

- ◈ 빅 데이터 수집 방법
  - 공공 데이터

'미세먼지'를 검색어로 입력하여 검색한 결과화면입니다.

파이형식으로 제공되는 데이터가 19건입니다. CSV 형식, XML 형식 등을 지원합니다.

공공 데이터 포털 사이트에 회원 가입하지 않아도 다운로드 가능합니다.

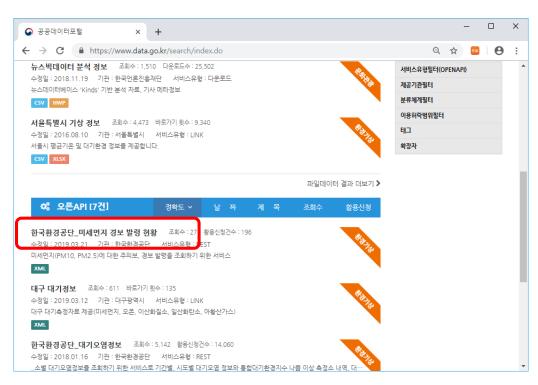


출처 : https://www.data.go.kr/

- ◈ 빅 데이터 수집 방법
  - 공공 데이터

파일 형식 뿐만 아니라 7건의 오픈 API 형식으로도 데이터가 제공됩니다.

리스트에서 제일 위에 있는 한국환경공단\_미세먼지 경보 발령 현황을 클릭하면

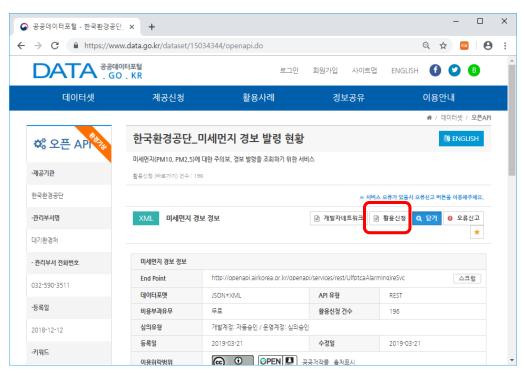


출처 : https://www.data.go.kr/

- ◈ 빅 데이터 수집 방법
  - 공공 데이터

한국환경공단\_미세먼지 경보 발령 현황 페이지로 옮겨가게 되며 활용신청을 클릭하여 활용 승인을 받아야 합니다.

활용신청은 회원가입을 해서 인증키를 받은 상태에서만 가능합니다.

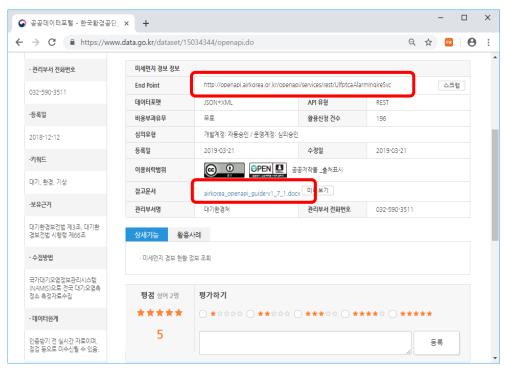


출처 : https://www.data.go.kr/

- ◈ 빅 데이터 수집 방법
  - 공공 데이터

오픈 API를 사용한다는 것은 요청하는 정해진 End Point에 해당하는 URL을 사용하여 정해 진 규격으로 프로그램을 구현하여 데이터를 수집해야 합니다.

그러므로 규격을 제공하는 도큐먼트 문서를 잘 검토해야 합니다.



출처 : https://www.data.go.kr/

#### ◈ 빅 데이터 수집 방법

- 공공 DB

#### [ 서울 열린 데이터 광장 ]

열린 데이터 광장은 열린 시정 3.0에 의해 공공 데이터를 민간에 개방하고 소통함으로써 공익성, 업무효율성, 투명성을 높이고 시만의 자발적 참여로 새로운 서비스와 공공의 가치를 창출할 수 있도록 하는 서비스입니다.



출처: https://data.seoul.go.kr/

- ◈ 빅 데이터 수집 방법
  - 공공 DB

[보건 의료 빅데이터 개방 시스템] 건강보험 심사평가원은 보건 의료 빅데이터 개방시스템을 통하여 국민과 보건의료 산업분야 그리고 의료연구기관 등 이용자에게 유익한 의료정보와 서비스를 제공하기 위해 공공데이터를 개방하고 있습니다.

보건의료 관련 공공데이터 파일 다운로드 및 신청과 Open API 검색 및 활용 신청을 지원합니다.



출처: https://opendata.hira.or.kr/home.do

- ◈ 빅 데이터 수집 방법
  - 공공 DB

#### [국가 통계 포털]

국가통계포털(KOSIS, Korean Statistical Information Service)은 국내, 국제, 북한의 주요 통계를 한 곳에 모아 이용자가 원하는 통계를 한 번에 찾을 수 있도록 통계청이 제공하는 One-Stop 통계 서비스입니다.



출처: http://kosis.kr/index/index.do

◈ 빅 데이터 수집 방법

- SNS

소셜 네트워킹 서비스(Social Networking Service)는 사용자 간의 자유로운 의사소통과 정보 공유, 그리고 인맥 확대 등을 통해 사회적 관계를 생성하고 강화해주는 온라인 플랫폼입니다.

최근 들어 스마트폰 이용자의 증가와 무선인터넷 서비스의 확장과 더불어 SNS의 이용자 또한 급증 하고 있습니다.



- ◈ 빅 데이터 수집 방법
  - SNS

[Open API]

OPEN API란 인터넷 이용자가 웹 검색 결과 및 사용자 화면 등을 제공받는 데 그치지 않고 직접 응용 프로그램과 서비스를 개발할 수 있도록 공개된 개발자를 위한 인터페이스입니다.

대부분의 SNS 사이트들은 개발자로 등록하고 인증키를 받아 제공되는 API를 사용합니다.

- 트위터: https://developer.twitter.com/
- 네이버 블로그 검색: https://developers.naver.com/docs/search/blog/
- 네이버 뉴스 검색 : https://developers.naver.com/docs/search/news/

- ◈ 빅 데이터 수집 방법
  - SNS

[RSS]

RSS는 Really Simple Syndication(혹은 Rich Site Summary)의 약칭으로 뉴스나 블로그와 같이 콘텐츠 업데이트가 자주 일어나는 웹사이트에서 업데이트된 정보를 정해진 규격의 XML형식으로 그리고 자동화 시켜서 사용자에게 제공하기 위한 서비스입니다.

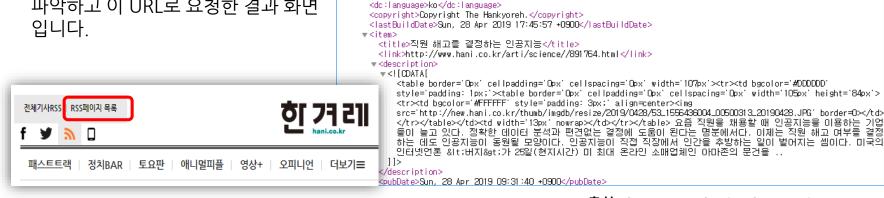
RSS가 등장하기 전에는 원하는 정보를 얻기 위해 해당 사이트를 직접 방문해야 했으나, RSS 관련 프로그램(혹은 서비스)을 이용하여 자동 수집이 가능해졌기 때문에 사용자는 각각의 사이트 방문 없이 최신 정보들만 골라 한 자리에서 볼 수 있습니다.

#### ◈ 빅 데이터 수집 방법

- SNS

[RSS]

한겨레 신문 홈페이지에서 RSS 이미지를 클릭한 후 RSS페이지 목록을 선택하여 과학 관련 RSS 컨텐트 URL 파악하고 이 URL로 요청한 결과 화면 입니다.



www.hani.co.kr/rss/science/

shown below.

▼ < channe l >

▼<description>

</description>

① 주의 요함 | www.hani.co.kr/rss/science/

<title> 전체기사 : 과학 : 뉴스 : 한겨레 뉴스 - 인터넷한겨레</title>

<![CDATA] 인터넷한겨레 - 토론이 살아 있는 생생한 인터넷뉴스 11>

▼<rss xmlns:dc="http://purl.org/dc/elements/1.1/" version="2.0">

<link>http://www.hani.co.kr/arti/science/</link>

This XML file does not appear to have any style information associated with it. The document tree is

출처: http://www.hani.co.kr/rss/science/

×

#### 간지 부분

- ◈ 웹 페이지를 구성하는 기술
  - 1. HTML과 CSS
  - 2. JavaScript
  - 3. Ajax

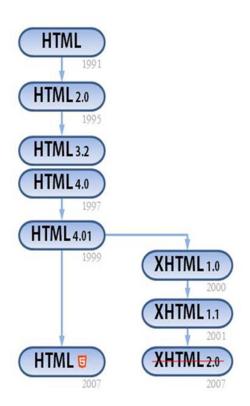
(기입하지 않습니다.)

- ◈ 웹 페이지를 구성하는 기술
  - HTML과 CSS

[HTML]

HTML이라는 용어는 1991년에 처음 사용되었고, 1995년 World Wide Web Consortium(이하 W3C) 에서 정식으로 HTML 2.0 표준안을 발표했습니다.

HTML은 웹(인터넷)에서 여러 가지 콘텐트를 보여주기 위하여 등장했던 언어로서 초기엔 텍스트 기반의 정보 전달이 목적이었으나 시간이 지나면서 텍스트 뿐만 아니라, 이미지, 오디오, 멀티미디어를 보여 주기 위한 목적으로 확정되었습니다.



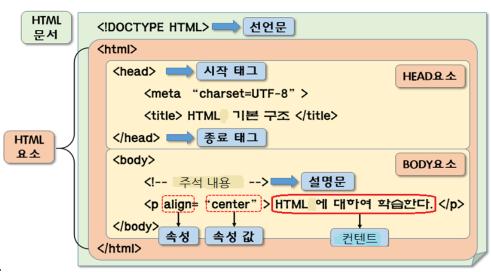
- ◈ 웹 페이지를 구성하는 기술
  - HTML과 CSS

#### [HTML]

웹 페이지를 만들 때 사용하는 HTML은 태그를 사용하여 내용을 작성합니다.

전체적으로 〈html〉 태그로 감싸지며 문서의 정보를 제공하는 〈head〉 태그와 브라우저에 랜더링되는 내용을 작성하는 〈body〉 태그로 구성됩니다.

웹 페이지에서 데이터를 추출한다는 것은 추출하려는 컨텐트의 태그를 찾아서 속성의 값이나 컨텐트 부분을 추출하는 것을 뜻합니다.

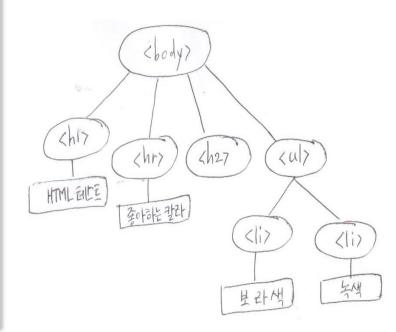


#### ◈ 웹 페이지를 구성하는 기술

- HTML과 CSS
[ HTML ]
브라우저가 HTML 문서를
파싱하여 브라우저의 도큐먼트 영역에 랜더링할 때
HTML 문서를 구성하는 모든 태그들과 속성 그리고 컨텐트들을 DOM이라는 규격을 적용하여 JavaScript 객체를 생성합니다.

HTML 문서의 내용으로 구성되는 DOM 객체들은 HTML 문서 그래도 계층 구조를 이루게 됩니다.

```
(head)
 (meta charset="utf-8")
 〈title〉테스트〈/title〉
</head>
(body)
 ⟨h1⟩HTML 테스트⟨/h1⟩
 (hr)
 〈h2〉좋아하는 칼라〈/h2〉
 (ul)
  (li)보라색(/li)
  〈li〉녹색〈/li〉
 (/ul)
</body>
</html>
```



- ◈ 웹 페이지를 구성하는 기술
  - HTML과 CSS [ CSS ]

CSS(Cascade Style Sheet)는 HTML과 같은 마크업 언어가 실제 표시되는 방법을 기술하는 언어로, HTML과 XHTML에 주로 사용됩니다.

#### [ CSS 사용의 이점 ]

- 웹 표준에 기반한 웹 사이트를 개발할 수 있습니다. (페이지의 내용과 디자인을 분리)
- 클라이언트 기기에 알맞는 반응형 웹 페이지를 개발 할 수 있습니다.
- 이미지의 사용을 최소화시켜 가벼운 웹 페이지 개발을 가능하게 합니다.

- ◈ 웹 페이지를 구성하는 기술
  - HTML과 CSS

앞에서 제시된 HTML 문서를 CSS 없이 랜더링 하면 위의 화면이 출력되며 다음과 같은 CSS를 적용하여 아래의 화면이 출력됩니다.

[ CSS의 작성 규칙 ]

```
선택자 {
        CSS속성명 : CSS속성값;
        CSS속성명 : CSS속성값;
        :
        :
```

```
⟨style⟩
  h1 {
    color: red:
    background-color: yellow;
    width: 250px;
    border: 3px solid magenta;
    border-radius: 10px;
    padding: 3px;
    text-align: center;
  h2 {
    color: blue:
    text-shadow: 2px 2px 2px skyblue;
</style>
```

# HTML 테스트

#### 좋아하는 칼라

- 보라색
- 녹색

## HTML 테스트

## 좋아하는 칼라

- 보라색
- 녹색

- ◈ 웹 페이지를 구성하는 기술
  - HTML과 CSS

[ CSS 선택자 ] CSS 선택자(selector)란 스타일을 적용하기 위해 대상 태그를 선택하는 방법입니다.

- 태그 선택자 태그명으로 태그를 선택하려는 경우로 태그명을 그대로 사용합니다. h2 { color : blue; }
- 클래스 선택자 태그에 정의된 class 속성의 값으로 태그를 선택하려는 경우로 . 과 함께 작성합니다. .redtext { color : red; }
- id 선택자 태그에 정의된 id 속성의 값으로 태그를 선택하려는 경우로 # 과 함께 작성합니다. #t1 { color : green; }

- ◈ 웹 페이지를 구성하는 기술
  - HTML과 CSS
    - 자식 선택자 지정된 부모 태그의 자식 태그에만 스타일이 적용됩니다. section > p { color : blue; }
    - 자손 선택자 지정된 부모 태그의 자식 태그에만 스타일이 적용됩니다. div p { color : yellow; }
    - 속성 선택자 태그에 정의된 속성과 값으로 태그를 선택하려는 경우로 [ ] 와 함께 작성합니다. img[src=duke.jpg] { radius : 0.5; }

- ◈ 웹 페이지를 구성하는 기술
  - JavaScript

JavaScript는 객체 기반의 스크립트 프로그래밍 언어로서 최근에는 다양한 기능의 프로그래밍에 사용 가능해 졌지만 주로 웹 페이지 개발 시 동적인 처리를 구현하기 위해 사용합니다.

JavaScript 코드는 〈script〉 태그와 함께 HTML 문서 내에 작성해도 되고 xxx.js 라는 독립된 파일로 만들어 〈script〉 태그를 이용하여 HTML 문서에서 호출하는 방식으로 작성해도 됩니다.

HTML 태그와 CSS만으로 구성되는 웹 페이지 즉, 정적으로 컨텐트가 구성되는 웹 페이지는 간단하게 컨텐트를 추출할 수 있지만 JavaScript를 이용하여 웹 페이지의 컨텐트가 동적으로 구성되는 경우에는 셀레니움과 같은 기술을 추가로 사용해야 합니다.

그러므로 웹 크롤링을 할 때는 크롤링하려는 컨텐트 부분이 정적으로 만들어진 것인지 JavaScript에 의해서 동적으로 만들어지는 것인지 부터 파악해야 합니다.

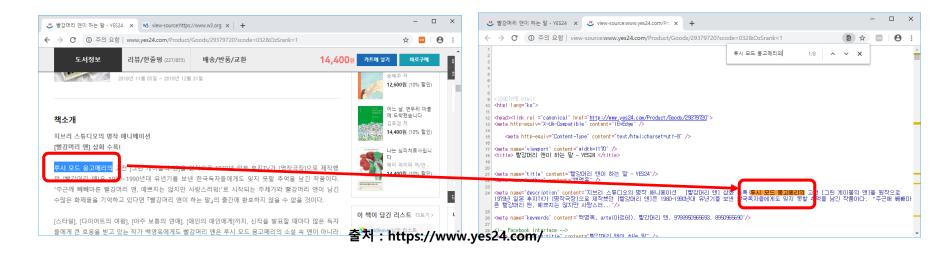
- ◈ 웹 페이지를 구성하는 기술
  - JavaScript

[ 정적인 컨텐트 생성와 동적인 컨텐트 생성의 예를 통한 비교 ]

정적인 컨텐트 생성은 왼편의 소스와 같이 HTML 만으로 구성되어 있습니다. 브라우저에서 이 문서를 요청할때마다 10시 30분 12초만 랜더링됩니다. 오른편 소스에서는 〈h1〉 태그에 컨텐트가 존재하지 않습니다. 대신 아래에 있는 JavaScript 코드가 수행되면 요청 시간을 기준으로한 시간이 랜더링됩니다. 이러한 페이지를 동적인 컨텐트 생성이라고 합니다.

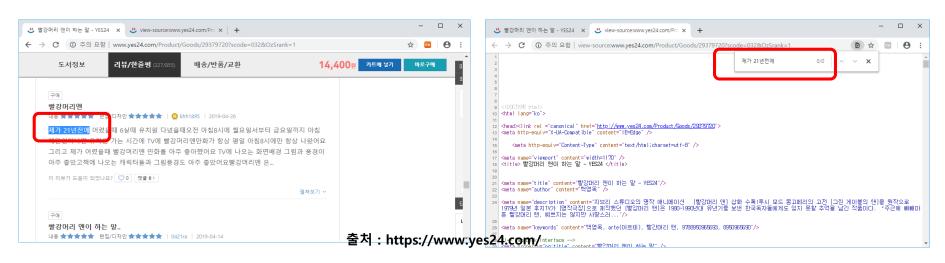
〈h1〉10시 30분 12초〈/h1〉

- ◈ 웹 페이지를 구성하는 기술
  - JavaScript
    [ 정적인 웹 컨텐트 점검 방법 ]
     브라우저로 점검하려고 하는 웹 페이지를 요청하여 랜더링한 다음 채크하려는 컨텐트의 일부분을 복사한 다음 브라우저의 소스보기 기능을 이용하여 출력되는 소스 내용에 복사한 내용을 검색하여 존재하는지 검색기능 으로 채크합니다. 다음과 같이 소스 내용으로 존재한다면 이 컨텐트는 정적으로 구성되는 내용입니다.



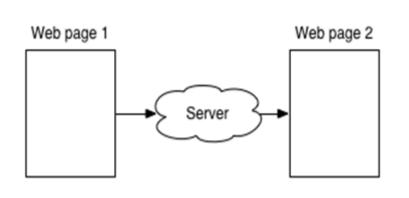
- ◈ 웹 페이지를 구성하는 기술
  - JavaScript [ 동적인 웹 컨텐트 점검 방법 ]

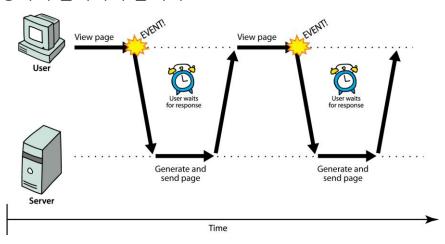
브라우저로 점검하려고 하는 웹 페이지를 요청하여 랜더링한 다음 채크하려는 컨텐트의 일부분을 복사한 다음 브라우저의 소스보기 기능을 이용하여 출력되는 소스 내용에 복사한 내용을 검색하여 존재하는지 검색기능으로 채크합니다. 다음과 같이 소스 내용으로 존재않는다면 이 컨텐트는 동적으로 구성되는 내용입니다.



- ◈ 웹 페이지를 구성하는 기술
  - Ajax

전통적인 웹의 통신 방법은 동기통신으로서 서버에 요청할 때마다 응답이 올 때까지 대기하게 됩니다. 서버에 요청을 할 때마다 브라우저에 보여지고 있는 끝난 현재 페이지는 지워집니다. 그러므로 페이지의 일부분만 변경하려는 경우에도 전체 페이지 내용을 요청하여 받아와야 합니다.

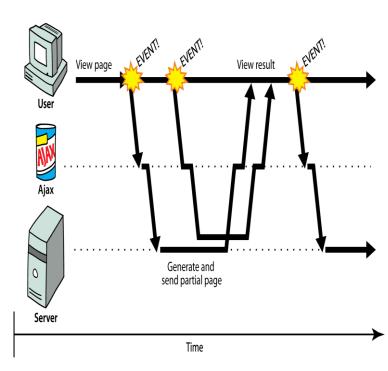




- ◈ 웹 페이지를 구성하는 기술
  - Ajax

Ajax는 Ajax Asynchronous JavaScript and XML의 약어입니다. JavaScript 코드로 서버와 통신하는 기술로서 통신 방식을 비동기적으로 처리하여 요청하고 나서 대기하지 않고 다른 작업을 처리할 수 있습니다. 또한 전체 페이지가 아닌 필요한 일부분만 요청하여 받아올 수 있는 통신입니다.

전체 페이지를 리로드(refresh)하지 않고 보여지고 있는 현재 페이지 내에 서버로 부터 받아온 내용을 자연스럽게 추가할 수 있으며 필요한 만큼의 일부 데이터만 요청하여 받는 기술이므로 빠르게 동적 웹 페이지를 생성하는 기술입니다. 특히 데이터 전송량이 중요한 모바일 웹 그리고 최근에 많이 활용되고 있는 SPA(single Page Application) 에서는 더욱 중요해진 통신 기술입니다.



- ◈ 웹 페이지를 구성하는 기술
  - Ajax [Ajax 기술을 사용한 페이지인지 확인하는 방법 ]

크롬 브라우저의 개발자 도구를 열고 네트워크 탭을 선택합니다. 네트워크 탭 에서는 웹 브라우저와 웹 서버간의 통신 상태 정보를 출력해 줍니다.

확인하고자 하는 웹 페이지를 요청합니다. 웹 페이지의 랜더링이 끝난 후에 개발자 도구를 보면 통신상태 정보 리스트가 출력 되면 여기에서 통신 Type 열을 채크했을 때 xhr 로 출력되는 통신은 Ajax 기술을 이용한 통신입니다.

